Clasificación de razas de gatos con redes convolucionales

CNN vs. MLP sobre el Oxford-IIIT Pet Dataset



Evaluación 2 · TLY1102 Técnicas de Machine Learning I

Grupo 7

Agustín Fernández · Sebastián Salgado · Eduardo Uribe

Octubre 2026

Matriz de responsabilidades

Distribución de tareas del Grupo 7

Integrante	Tareas realizadas
Agustín Fernández	Preparación de datos, lógica de extracción del dataset, validación de normalización y EDA.
Sebastián Salgado	Diseño e implementación de la arquitectura CNN y visualización de Feature Maps.
Eduardo Uribe	Entrenamiento, evaluación comparativa CNN vs. MLP, análisis Grad-CAM y redacción final.

El problema: 12 razas con pocos datos

12	1.517	379	475
razas de gatos	entrenamiento	validación	prueba

Variante del grupo

- Solo gatos (SPECIES = 1); se descartan los perros
- Partición 80/20 por raza (seed 29), igual que el MLP
- Imágenes de 64 × 64 RGB

¿Por qué una CNN?

- El MLP aplana la imagen y pierde el contexto espacial entre píxeles
- La CNN conserva la forma 2D y extrae bordes, texturas y partes
- Se compara con el MLP de la E1 en el mismo conjunto de prueba

Preparación de datos para la CNN

1. **Filtrar gatos**
   12 razas
2. **Partición**
   80/20 por raza
3. **Redimensionar**
   64 × 64 px
4. **Normalizar**
   ÷ 255 ⟶ [0, 1]
5. **Validación**
   20 % del train

Adaptación respecto al MLP

Cada imagen se mantiene como tensor (64, 64, 3). El Flatten aparece solo al final, tras extraer características. Misma resolución, normalización y partición que el MLP.

Corrección a la Evaluación 1

La validación del MLP se solapaba con el entrenamiento (shuffle=False) y queda inflada. Ahora usa shuffle=True y no comparte imágenes con el train.

Arquitectura: 3 bloques Convencionales + Pooling



320.172

parámetros entrenables (1,22 MB)

- ReLU en las capas ocultas, softmax en la salida
- Sin Dropout ni BatchNormalization: la evaluación no permite capas de regularización

Justificación de las decisiones

1 3 convoluciones (16→32→64)

Jerarquía bordes → texturas → partes. Pocos filtros: con ~1.500 imágenes memoriza fácil.

2 Filtros 3 × 3

Campo receptivo amplio al apilarlos, con pocos parámetros.

3 MaxPooling 2 × 2

Reduce a la mitad el mapa de características , baja parámetros y da invarianza a traslaciones.

4 ReLU + Softmax

ReLU permite valores positivos sin límite, y Softmax entrega la probabilidad de cada una de las 12 razas.

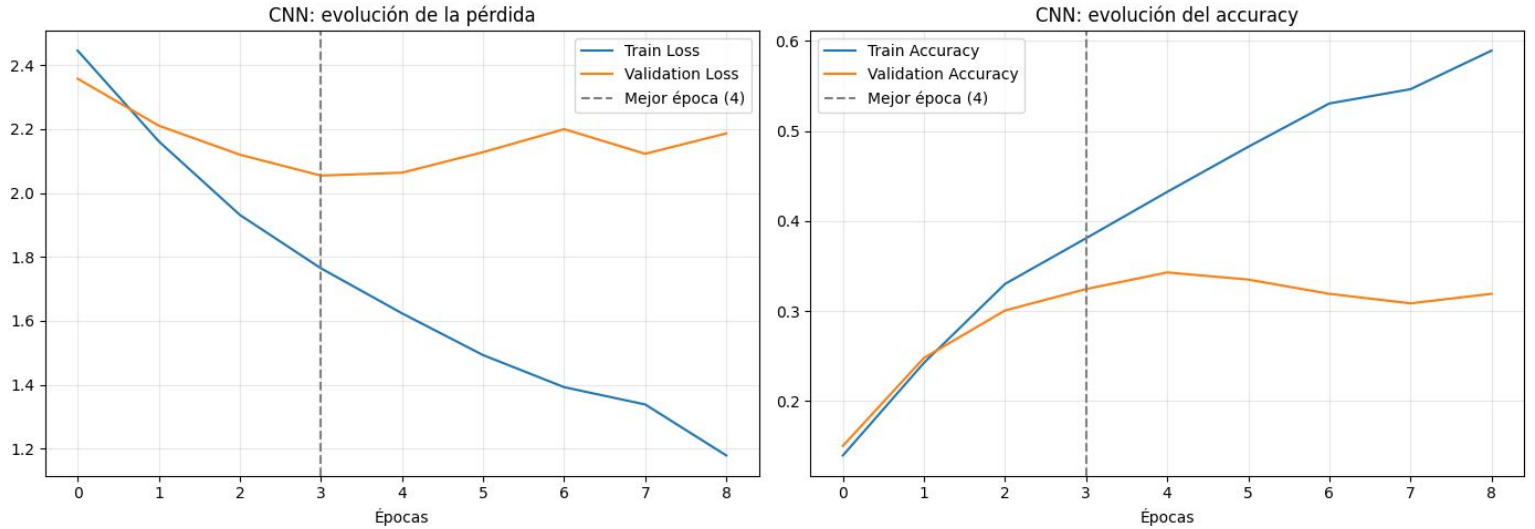
5 Adam + sparse CCE

Tiene una muy buena tasa adaptativa, etiquetas enteras sin one-hot.

6 EarlyStopping

Detiene el entrenamiento y restaura los mejores pesos.

Entrenamiento: sobreajuste desde la época 4



Época 4

mejor val_loss (2,054)

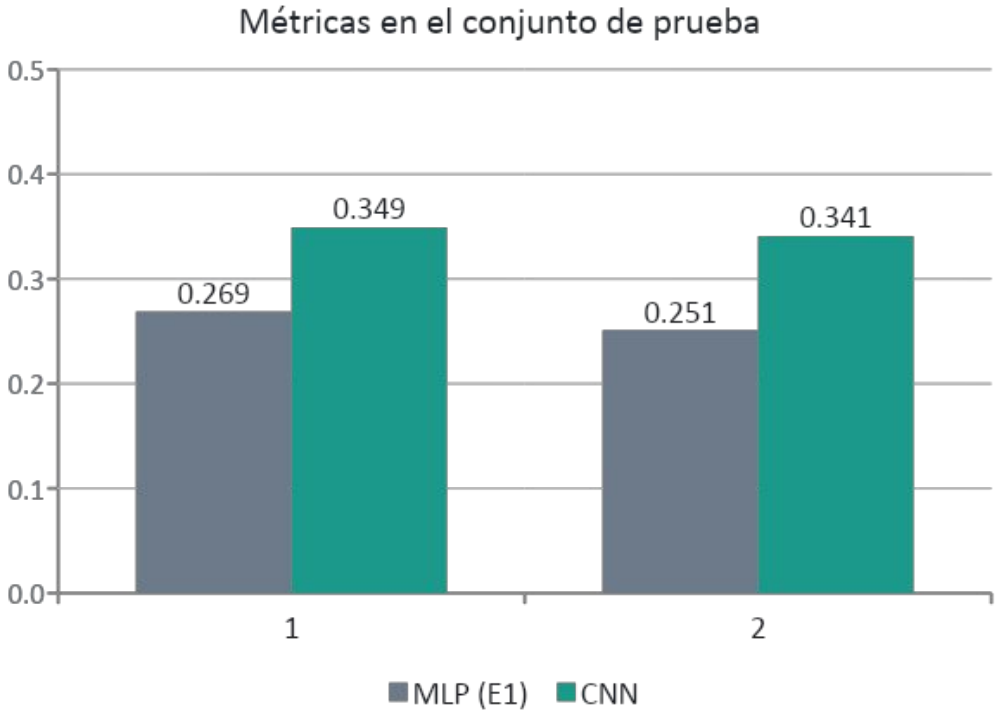
9 de 30

épocas (EarlyStopping)

0,59 vs 0,32

acc. train vs val al final

La CNN supera al MLP en prueba



+0,08

de accuracy (0,349 vs 0,269)

−80 %

de parámetros (1,58 M → 320 k)

87 vs 49

imágenes que solo la CNN o solo el MLP aciertan

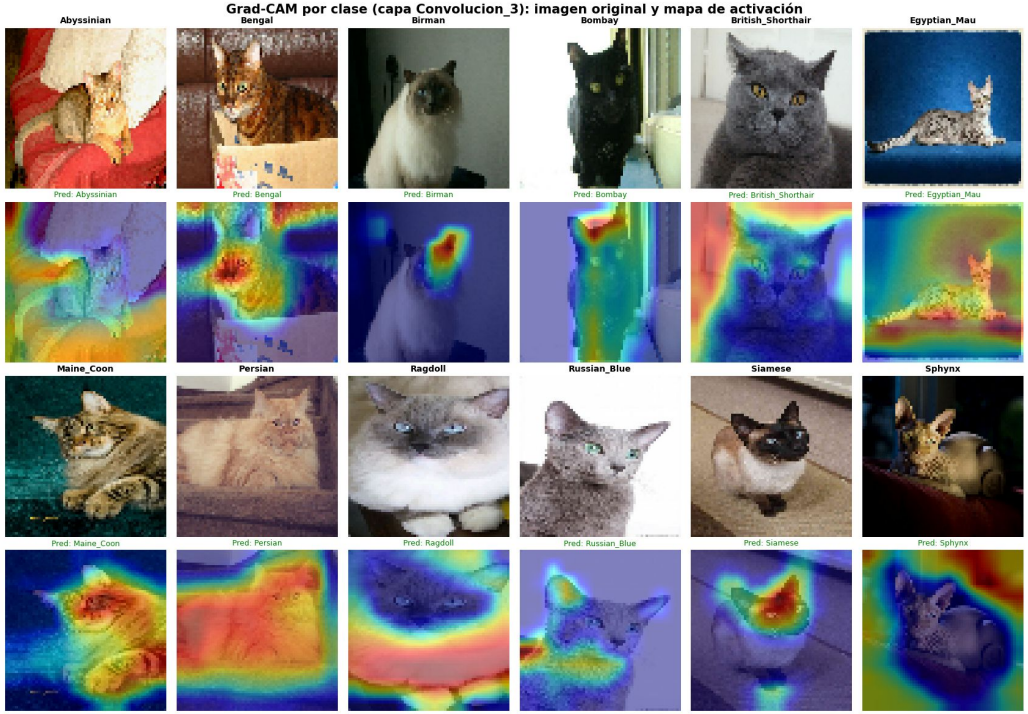
Costo y capacidad de generalización

Métrica	MLP (E1)	CNN
Parámetros	1.582.028	**320.172**
Épocas	30	9 (EarlyStopping)
Tiempo total	**11,5 s**	79,6 s
Tiempo por época	**0,38 s**	8,84 s
Acc. entrenamiento	0,371	0,430
Acc. validación	0,216	**0,325**
Acc. prueba	0,269	**0,349**
Brecha train–test	0,102	**0,081**

Lectura

- La CNN es más lenta por época: las convoluciones cuestan más computo.
- Aun así usa 80 % menos parámetros y generaliza mejor.
- Los tiempos totales no son estrictamente comparables ya que tiene distinto nº de épocas y ejecuciones.

Errores y mapas de activación



Mejor y peor raza

Bombay F1 0,71 · Abyssinian F1 0,23

Confusión típica

Birman → Siamese (14); varias razas → Sphynx

Confianza media

0,51 en aciertos vs 0,37 en errores

Grad-CAM

En varias razas el calor cae sobre el fondo, no sobre el gato

Conclusiones

1

Qué logramos

La CNN supera al MLP en accuracy, precision, recall y F1, con 80 % menos parámetros. La causa es arquitectónica: conserva la estructura espacial.

2

Qué limita

Con ~1.500 imágenes, 12 razas parecidas, 64 × 64 px y sin regularización, la red se sobreajusta. EarlyStopping lo limita pero no lo elimina.

3

Qué sigue

Subir la resolución a 128 × 128 y agregar Dropout para reducir el sobreajuste.